

Genome Normalizer

GitHub repozitár + produkčná prevádzka na Railway

Architektúra / dátový tok / API / bezpečnosť / DEMO režim / referenčné dáta / nasadzovanie / diagnostika

Verzia aplikácie	2.3
Stav dokumentu	8. októbra 2026
Repozitár	github.com/umbaja/imputation
Produkcia	genome-normalizer-production.up.railway.app

DÔLEŽITÉ: Vlastnícke Railway heslo nie je súčasťou dokumentu. Uvedené DEMO údaje sú zámerne verejné a serverovo obmedzené.



Prevádzkový stav

Dokument zachytáva overený produkčný stav po nasadení DEMO režimu a technickej dokumentácie.

APLIKÁCIA	DEPLOYMENT	CI TESTY	REFERENCIE
v2.3	SUCCESS	20 / 20	23 bref3

Kľúčové pravidlo: sibling/IBD vetva používa iba priamo namerané genotypy. Cielená imputácia je izolovaná v predispozičnom výstupe.

1. Účel systému

Genome Normalizer prijíma genotypové súbory z rôznych platforiem a vytvorí jednotný normalizovaný genotyp v zostave GRCh37 na plus vlákne. Kanonický textový výstup má štyri tabulátorom oddelené stĺpce: `rsid`, `chromosome`, `position`, `genotype`. No-call hodnota je `--`.

Z jedného normalizovaného zdroja vznikajú dve striktne oddelené analytické vetvy:

- 1 sibling/IBD dataset obsahuje iba priamo namerané genotypy;
- 2 predispozičný dataset používa vstavaný 561-SNP panel a môže doplniť chýbajúce panelové lokusy cieľenou imputáciou Beagle/1000 Genomes.

Imputované lokusy sa nikdy nepridávajú do sibling/IBD datasetu. Toto pravidlo bráni tomu, aby sa panelové odhady nesprávne použili ako meraný dôkaz príbuznosti.

2. Podporované vstupy

- 23andMe raw data;
- AncestryDNA;
- MyHeritage a FamilyTreeDNA;
- Illumina GenomeStudio Final Report;
- VCF;
- PLINK PED/MAP;
- WGS/WES VCF s voliteľným BAM pri lokálnej prevádzke.

Formát sa deteguje z autoritatívnej hlavičky a štruktúry stĺpcov, nie iba z názvu súboru. Illumina musí poskytovať alely na plus vlákne alebo mať validovanú manifestovú konverziu. Neistý TOP/BOT export sa odmieta.

3. Dátový tok

```
surový genotyp
-> detekcia formátu
-> parser platformy
-> normalizácia chromozómu, pozície, alel a no-call hodnôt
-> normalizovaný GRCh37/plus genotyp
    |-> sibling/IBD: iba merané lokusy
    `-> 561-SNP predispozičný panel
        |-> measured
        |-> no_call/absent
        `-> Beagle + 1000G -> imputed, iba ak max(GP) >= 0,90
```

Normalizácia zoraďuje chromozómy a pozície, stabilizuje diploidné alely a zachováva pôvodné namerané volania. Panelová kontrola páruje prednostne podľa rsID a následne podľa `chromosome:position`. Lokálna ID referencia môže doplniť chýbajúcu súradnicu bez odoslania genotypu na internet.

Pri imputácii `targeted_impute.sh` vytvorí VCF, zoradí a indexuje ho, zoskupí ciele do okien, pre príslušné chromozómy spustí Beagle, zlúči regióny a extrahuje iba cieľové SNP. Predvolený prah je $\max(GP)$ 0,90. Namerané volanie má vždy prednosť pred imputovaným.

4. Výstupy

- `*_normalized_genotype.txt` alebo `*.normalized_grch37.txt` - normalizovaný genotyp;
- `*_sibling_measured_normalized.txt` - sibling/IBD vstup bez imputácie;
- `*_predisposition_normalized.txt` - normalizovaný predispozičný výstup;
- `*_predisposition_status.csv` - stav každého SNP pred imputáciou;
- `*_predisposition_missing.csv` - lokusy navrhnuté na imputáciu;
- `*_predisposition_panel.csv` - merané, prijaté imputované a chýbajúce SNP;
- `*.preparation_report.json` - QC, počty, pôvod a upozornenia.

5. Softvérová architektúra

Komponent	Zodpovednosť
<code>app/main.py</code>	FastAPI, middleware, jednotlivé API kroky, DEMO, downloady
<code>app/batch.py</code>	kompletná viac-kroková pipeline a progres dávky
<code>app/runtime_security.py</code>	autentifikácia, roly, limity, retencia, globálny job lock
<code>dna_tools/detect.py</code>	automatická detekcia vstupného formátu
<code>dna_tools/parsers.py</code>	parsery platforiem do GenotypeData
<code>dna_tools/convert.py</code>	normalizovaný štvorstĺpcový export a merge imputácie
<code>dna_tools/panel.py</code>	kontrola pokrytia 561-SNP alebo vlastného panela
<code>dna_tools/analysis_prep.py</code>	stabilný CLI integračný bod pre obe vetvy
<code>targeted_impute.sh</code>	cielená Beagle/1000G imputácia
<code>setup_reference.sh</code>	stiahnutie, veľkostná a SHA-256 kontrola referencií
<code>deploy/start.sh</code>	Railway bootstrap a štart Uvicornu na \$PORT
<code>static/index.html</code>	samostatné webové UI bez frontend frameworku

Pythonová časť používa FastAPI, Uvicorn, pandas, python-multipart a pyliftover. Kontajner dopĺňa Java runtime, bcftools, bgzip/tabix, samtools, curl, unzip a gzip.

6. API

Metóda a cesta	Funkcia
GET /healthz	verejný Railway health check
GET /api/status	verzia, rola, referencia a pripravenosť nástrojov
POST /api/detect	detekcia vstupného formátu
POST /api/convert	vytvorenie normalizovaného genotypu
POST /api/panel-check	pokrytie panelových SNP
POST /api/impute-plan	výpočet cieľových okien
POST /api/impute-run	asynchrónne spustenie imputácie
GET /api/impute-progress/{id}	progres imputácie
POST /api/merge-final	vytvorenie predispozičného výstupu
POST /api/batch-run	kompletná pipeline pre 1-5 vzoriek
GET /api/batch-progress/{id}	progres dávky
POST /api/batch-cancel/{id}	požiadavka na zrušenie dávky
POST /api/demo-run	syntetická normalizácia a panelová kontrola
GET /api/demo-download/{kind}	pevne povolené DEMO súbory
GET /api/download/{name}	výstupy plného účtu z pracovného adresára

Vo verejnom režime sú Swagger/OpenAPI a /api/logs vypnuté.

7. DEMO účet

Produkčný DEMO účet je určený na verejnú prezentáciu:

```
používateľ: demo
heslo: genome-demo-2026
```

Súbor `demo/demo_myheritage_raw.csv` je syntetický a nepatrí žiadnej osobe. Kliknutie na „Spustiť demo analýzu“ používa reálny parser MyHeritage, normalizačný export a kontrolu vstavaného 561-SNP panela. Používateľ vidí náhľad, počty a môže stiahnuť vstup, normalizovaný genotyp, sibling dataset, panel CSV a sanitizovanú JSON správu.

DEMO middleware povoľuje iba `/`, `/api/status`, `/api/demo-run`, DEMO downloady a statické súbory. Vlastné uploady, všeobecné downloady, logy, dávková pipeline a Beagle sú blokované odpoveďou HTTP 403. Beagle sa v deme zámerne nespúšťa, aby zdieľaný účet nemohol spotrebovať výpočtové zdroje.

8. GitHub

Zdrojový repozitár je verejný `umbaja/imputation`; produkčná vetva je `main`. Push do `main` spustí dve nezávislé udalosti:

- 1 GitHub Actions workflow `.github/workflows/tests.yml` nainštaluje balík na Python 3.11, spustí všetky `unittest` testy a overí syntax troch shell skriptov;
- 2 Railway GitHub integrácia zostaví nový Docker image a nasadí ho do produkčného prostredia.

Do Gitu sa neukladajú surové genetické dáta, pracovné výstupy ani veľké referencie. `.gitignore` blokuje okrem iného `work/`, `out/`, `results/`, `samples/`, `uploads/`, `ref/`, VCF, BAM, PLINK a odvodené indexy. Verzované sú iba kód, malý 561-SNP panel, lokálna komprimovaná ID mapa, syntetické demo a manifest referencií.

9. Railway produkcia

Položka	Hodnota
projekt	genome-normalizer
environment	production
service	genome-normalizer
doména	genome-normalizer-production.up.railway.app
build	koreňový Dockerfile, Python 3.11 slim
start	bash deploy/start.sh
port	Railway premenná \$PORT, aktuálne smerovaná na 8080
volume	genome-normalizer-volume
mount	/app/ref
kapacita	50 000 MB; využitie po bootstrapovaní približne 12 128 MB
repliky	1
región	Railway predvolený US East

Premenné prostredia

Premenná	Produkčná hodnota alebo význam
PUBLIC_MODE	1
APP_USERNAME	vlastník; hodnota nie je dokumentovaná ako verejný údaj
APP_PASSWORD	tajný Railway secret
DEMO_USERNAME	demo
DEMO_PASSWORD	genome-demo-2026 - zámerne verejné demo heslo
BOOTSTRAP_REFERENCE	1
REFERENCE_DIR	/app/ref
BEAGLE_JAR	/app/ref/beagle.jar
REF_DIR	/app/ref/b37.bref3
MAP_DIR	/app/ref/maps
FASTA	/app/ref/human_g1k_v37.fasta
JOBS	1
XXM_JOB	3g
RUNTIME_RETENTION_HOURS	6
MAX_UPLOAD_MB	100

Premenná	Produkčná hodnota alebo význam
MAX_REQUEST_MB	250
MAX_BATCH_SAMPLES	5
RAILWAY_HEALTHCHECK_TIMEOUT_SEC	3600

APP_PASSWORD sa nesmie commitnúť, zapisovať do technickej správy ani zverejniť v logu. Zmena vlastného hesla sa robí iba cez Railway Variables a vyvolá nové nasadenie.

10. Referenčné dáta a prvý štart

reference_manifest.tsv pripína URL, presnú veľkosť a SHA-256 každého súboru:

- Beagle JAR;
- genetické mapy GRCh37;
- 23 brief3 panelov pre chromozómy 1-22 a X z 1000 Genomes phase 3;
- komprimovanú a rozbalenú human_g1k_v37.fasta.

Pri prvom štarte deploy/start.sh overí, či je referencia kompletná. Ak nie, spustí setup_reference.sh. Download používa resume, každý súbor sa pred presunom z .part overí veľkosťou a SHA-256, mapy sa rozbalia a samtools vytvorí FASTA index .fai. Aplikácia sa spustí až po úspešnej kontrole.

Volume je persistentný, preto ďalší deployment iba skontroluje prítomnosť Beagle, FASTA, .fai, 23 brief3 panelov a 23 máp. Kód a /app/work sú na ephemérálnom filesystéme kontajnera; referencie zostávajú na volume.

11. Bezpečnosť a životný cyklus dát

- verejný režim zlyhá pri štarte, ak chýba vlastné meno alebo heslo;
- HTTP Basic Auth rozlišuje rolu owner a demo pomocou constant-time porovnania;
- TLS končí na Railway edge;
- odpovede nastavujú Cache-Control: no-store, HSTS, nosniff, zákaz iframe, nulový referrer a zákaz kamery/mikrofónu/geolokácie;
- upload sa streamuje po 1 MB a pri prekročení limitu sa čiastočný súbor zmaže;
- názov uploadu dostane náhodný prefix a download povoľuje iba basename v pracovnom adresári;
- verejný režim vypína online anotáciu a BAM adresár;
- jeden procesový JOB_LOCK povoľuje najviac jednu imputáciu naraz;
- pracovné súbory sa mažu približne po 6 hodinách a vždy sa stratia pri redeployi; referenčný volume sa nemaže;
- aplikačné logy nie sú vo verejnom režime dostupné cez API.

HTTP Basic Auth je prevádzkové minimum, nie kompletný systém používateľských účtov. Pred spracovaním genetických údajov tretích osôb treba doplniť právny základ, informovaný súhlas, audit, incidentný proces a podľa požiadaviek aj šifrovanie uložených dát vlastným kľúčom.

12. Prevádzka a diagnostika

Základná kontrola:

```
curl https://genome-normalizer-production.up.railway.app/healthz
```

Po vlastníckom prihlásení `/api/status` musí hlásiť `java: true, beagle_jar: true, fasta: true, bref3_files: 23, default_panel: true a imputation_ready: true`.

Lokálne testy:

```
python -m unittest discover -s tests -v
bash -n targeted_impute.sh
bash -n setup_reference.sh
bash -n deploy/start.sh
```

Overenie existujúcej referencie bez siete:

```
REFERENCE_DIR=/app/ref bash setup_reference.sh --verify-only
```

Najčastejšie poruchy:

- `imputation_ready=false`: skontrolovať Java, cesty premenných a obsah volume;
- chýbajúci chromozóm: porovnať súbor s `reference_manifest.tsv` a znovu spustiť bootstrap;
- HTTP 401: nesprávne Basic Auth údaje;
- HTTP 403 na DEMO účte: požadovaná funkcia je úmyselne povolená iba vlastníkom;
- HTTP 409: iná imputácia drží globálny zámok;
- HTTP 413: upload alebo celá požiadavka prekročila nastavený limit;
- nedostatočný sibling prienik: výsledok označiť ako nedostatočné dáta, nie dopĺňať 561 panelových SNP do IBD vetvy.

13. Limity

- Základná zostava je GRCh37/hg19; hg38 vyžaduje validovaný liftover.
- Produkčné WGS/WES pomocné referencie nie sú v aktuálnom Railway nasadení kompletne; čipová normalizácia a cielená panelová imputácia sú pripravené.
- Presná uzavretá markerová šablóna platformy v5 nie je súčasťou repozitára. Predvolený výstup preto zachováva plný meraný markerový set v otvorenej normalizovanej schéme.
- Predispozičný výstup je výskumný a informatívny, nie klinická diagnóza. Klinicky významný nález musí potvrdiť akreditované laboratórium.

Koniec technickej správy. Aktuálny zdroj pravdy je vetva main v GitHub repozitári projektu.