



TECHNICKÁ SPRÁVA / 2026

Genome Normalizer

Normalizácia multiplatformových genotypov pre sibling/IBD analýzu a oddelené hodnotenie predispozícií.

DEMO ÚČET demo

genome-demo-2026

Iba syntetická ukážka, bez vlastného uploadu.

TESTOVACÍ ÚČET test

heslo: súkromný Railway secret

Ostrá pipeline, spoločný limit 5 genotypov denne.

GITHUB + RAILWAY / PREVÁDZKOVÁ DOKUMENTÁCIA

Repozitár	github.com/umbaja/imputation
Produkcia	genome-normalizer-production.up.railway.app
Verzia	2.4 / stav k 8. októbru 2026

Technický a prevádzkový prehľad

Dokument pokrýva dátový tok, API, účty, dennú kvótu, GitHub workflow, Railway infraštruktúru, referencie, bezpečnosť a diagnostiku.

- | | |
|----------------------------------|-------------------------------------|
| 1. Účel systému | 2. Podporované vstupy |
| 3. Dátový tok | 4. Výstupy |
| 5. Softvérová architektúra | 6. API |
| 7. DEMO účet | 8. Testovací účet |
| 9. GitHub | 10. Railway produkcia |
| 11. Referenčné dáta a prvý štart | 12. Bezpečnosť a životný cyklus dát |
| 13. Prevádzka a diagnostika | 14. Limity |

DÔLEŽITÉ ROZLIŠENIE

DEMO heslo je verejné, pretože rola pracuje iba so syntetickým súborom. TEST heslo zostáva súkromným Railway secretom, pretože rola prijíma reálne genetické dáta a spúšťa ostrú pipeline.

1. Účel systému

Genome Normalizer prijíma genotypové súbory z rôznych platforiem a vytvorí jednotný normalizovaný genotyp v zostave GRCh37 na plus vlákne. Kanonický textový výstup má štyri tabulátorom oddelené stĺpce: `rsid`, `chromosome`, `position`, `genotype`. No-call hodnota je `--`.

Z jedného normalizovaného zdroja vznikajú dve striktne oddelené analytické vetvy:

- 1 sibling/IBD dataset obsahuje iba priamo namerané genotypy;
- 2 predispozičný dataset používa vstavaný 561-SNP panel a môže doplniť chýbajúce panelové lokusy cielenou imputáciou Beagle/1000 Genomes.

Imputované lokusy sa nikdy nepridávajú do sibling/IBD datasetu. Toto pravidlo bráni tomu, aby sa panelové odhady nesprávne použili ako meraný dôkaz príbuznosti.

2. Podporované vstupy

- 23andMe raw data;
- AncestryDNA;
- MyHeritage a FamilyTreeDNA;
- Illumina GenomeStudio Final Report;
- VCF;
- PLINK PED/MAP;
- WGS/WES VCF s voliteľným BAM pri lokálnej prevádzke.

Formát sa deteguje z autoritatívnej hlavičky a štruktúry stĺpcov, nie iba z názvu súboru. Illumina musí poskytovať alely na plus vlákne alebo mať validovanú manifestovú konverziu. Neistý TOP/BOT export sa odmieta.

3. Dátový tok

```
surový genotyp
-> detekcia formátu
-> parser platformy
-> normalizácia chromozómu, pozície, alel a no-call hodnôt
-> normalizovaný GRCh37/plus genotyp
|-> sibling/IBD: iba merané lokusy
`-> 561-SNP predispozičný panel
|-> measured
|-> no_call/absent
`-> Beagle + 1000G -> imputed, iba ak max(GP) >= 0,90
```

Normalizácia zoraďuje chromozómy a pozície, stabilizuje diploidné alely a zachováva pôvodné namerané volania. Panelová kontrola páruje prednostne podľa rsID a následne podľa `chromosome:position`. Lokálna ID referencia môže doplniť chýbajúcu súradnicu bez odoslania genotypu na internet.

Pri imputácii `targeted_impute.sh` vytvorí VCF, zoradí a indexuje ho, zoskupí ciele do okien, pre príslušné chromozómy spustí Beagle, zlúči regióny a extrahuje iba cieľové SNP. Predvolený prah je `max(GP) 0,90`. Namerané volanie má vždy prednosť pred imputovaným.

4. Výstupy

- `*_normalized_genotype.txt` alebo `*.normalized_grch37.txt` - normalizovaný genotyp;
- `*_sibling_measured_normalized.txt` - sibling/IBD vstup bez imputácie;
- `*_predisposition_normalized.txt` - normalizovaný predispozičný výstup;
- `*_predisposition_status.csv` - stav každého SNP pred imputáciou;

- *_predisposition_missing.csv - lokusy navrhnuté na imputáciu;
- *_predisposition_panel.csv - merané, prijaté imputované a chýbajúce SNP;
- *.preparation_report.json - QC, počty, pôvod a upozornenia.

5. Softvérová architektúra

Komponent	Zodpovednosť
app/main.py	FastAPI, middleware, jednotlivé API kroky, DEMO, downloady
app/batch.py	kompletná viac-kroková pipeline a progres dávky
app/runtime_security.py	autentifikácia, roly, limity, retencia, globálny job lock
dna_tools/detect.py	automatická detekcia vstupného formátu
dna_tools/parsers.py	parser platformy do GenotypeData
dna_tools/convert.py	normalizovaný štvorstĺpcový export a merge imputácie
dna_tools/panel.py	kontrola pokrytia 561-SNP alebo vlastného panela
dna_tools/analysis_prep.py	stabilný CLI integračný bod pre obe vetvy
targeted_impute.sh	cieľená Beagle/1000G imputácia
setup_reference.sh	stiahnutie, veľkosť a SHA-256 kontrola referencií
deploy/start.sh	Railway bootstrap a štart Uvicornu na \$PORT
static/index.html	samostatné webové UI bez frontend frameworku

Pythonová časť používa FastAPI, Uvicorn, pandas, python-multipart a pydantic. Kontajner dopĺňa Java runtime, bcftools, bgzip/tabix, samtools, curl, unzip a gzip.

6. API

Metóda a cesta	Funkcia
GET /healthz	verejný Railway health check
GET /api/status	verzia, rola, referencia a pripravenosť nástrojov
POST /api/detect	detekcia vstupného formátu
POST /api/convert	vytvorenie normalizovaného genotypu
POST /api/panel-check	pokrytie panelových SNP
POST /api/impute-plan	výpočet cieľových okien
POST /api/impute-run	asynchrónne spustenie imputácie
GET /api/impute-progress/{id}	progres imputácie
POST /api/merge-final	vytvorenie predispozičného výstupu
POST /api/batch-run	kompletná pipeline pre 1-5 vzoriek
GET /api/batch-progress/{id}	progres dávky
POST /api/batch-cancel/{id}	požiadavka na zrušenie dávky
POST /api/demo-run	syntetická normalizácia a panelová kontrola
GET /api/demo-download/{kind}	pevne povolené DEMO súbory
GET /api/download/{name}	výstupy plného účtu z pracovného adresára

Vo verejnom režime sú Swagger/OpenAPI a /api/logs vypnuté.

7. DEMO účet

Produkčný DEMO účet je určený na verejnú prezentáciu:

používateľ: demo
heslo: genome-demo-2026

Súbor `demo/demo_myheritage_raw.csv` je syntetický a nepatrí žiadnej osobe. Kliknutie na „Spustiť demo analýzu“ používa reálny parser MyHeritage, normalizačný export a kontrolu vstavaného 561-SNP panela. Používateľ vidí náhľad, počty a môže stiahnuť vstup, normalizovaný genotyp, sibling dataset, panel CSV a sanitizovanú JSON správu.

DEMO middleware povoľuje iba `/`, `/api/status`, `/api/demo-run`, DEMO downloads a statické súbory. Vlastné uploads, všeobecné downloads, logy, dávková pipeline a Beagle sú blokované odpoveďou HTTP 403. Beagle sa v deme zámerne nespúšťa, aby zdieľaný účet nemohol spotrebovať výpočtové zdroje.

8. Testovací účet

Produkčný TEST účet je určený na obmedzené spracovanie vlastných genotypov v ostrej Railway prevádzke:

používateľ: test
heslo: súkromný Railway secret, odovzdáva sa oprávneným testerom
limit: 5 genotypov za kalendárny deň

TEST používa rovnakú produkčnú pipeline, referencie Beagle/1000 Genomes a 561-SNP panel ako vlastník. Webové rozhranie mu sprístupní kompletnú dávkovú pipeline, progres, zrušenie úlohy a stiahnutie výsledkov. Manuálne servisné kroky a aplikačné logy sú pre túto zdieľanú rolu zablokované.

Limit je spoločný pre všetkých používateľov tohto účtu, nie päť genotypov na jednu osobu. Každá vzorka v serverom prijatej dávke spotrebuje jednu jednotku; neskoršia chyba počas výpočtu ju automaticky nevracia. Server kvótu kontroluje atomicky a po vyčerpaní odpovie HTTP 429. Nový deň začína o polnoci v časovom pásme [Europe/Bratislava](#). Počítadlo je uložené v `/app/ref/test_account_quota.json` na persistentnom Railway volume, preto ho reštart ani redeploy nevynuluje.

Účet spracúva reálne genetické údaje. Používateľ ho smie použiť iba s právnym základom a informovaným súhlasom dotknutej osoby. Výstupy sa s pracovnými súbormi automaticky mažu približne po šiestich hodinách; samotná denná kvóta ostáva zachovaná na volume.

9. GitHub

Zdrojový repozitár je verejný `umbaja/imputation`; produkčná vetva je `main`. Push do `main` spustí dve nezávislé udalosti:

- 1 GitHub Actions workflow `.github/workflows/tests.yml` nainštaluje balík na Python 3.11, spustí všetky `unittest` testy a overí syntax troch shell skriptov;
- 2 Railway GitHub integrácia zostaví nový Docker image a nasadí ho do produkčného prostredia.

Do Gitu sa neukladajú surové genetické dáta, pracovné výstupy ani veľké referencie. `.gitignore` blokuje okrem iného `work/`, `out/`, `results/`, `samples/`, `uploads/`, `ref/`, VCF, BAM, PLINK a odvodené indexy. Verzované sú iba kód, malý 561-SNP panel, lokálna komprimovaná ID mapa, syntetické demo a manifest referencií.

10. Railway produkcia

Položka	Hodnota
projekt	genome-normalizer
environment	production
service	genome-normalizer
doména	genome-normalizer-production.up.railway.app
build	koreňový Dockerfile, Python 3.11 slim
start	bash deploy/start.sh

Položka	Hodnota
port	Railway premenná \$PORT, aktuálne smerovaná na 8080
volume	genome-normalizer-volume
mount	/app/ref
kapacita	50 000 MB; využitie po bootstrapovaní približne 12 128 MB
repliky	1
región	Railway predvolený US East

Premenné prostredia

Premenná	Produkčná hodnota alebo význam
PUBLIC_MODE	1
APP_USERNAME	vlastník; hodnota nie je dokumentovaná ako verejný údaj
APP_PASSWORD	tajný Railway secret
DEMO_USERNAME	demo
DEMO_PASSWORD	genome-demo-2026 - zámerne verejné demo heslo
TEST_USERNAME	test
TEST_PASSWORD	súkromný Railway secret; nepublikuje sa v repozitári ani správe
TEST_DAILY_LIMIT	5 genotypov za deň
TEST_QUOTA_TIMEZONE	Europe/Bratislava
TEST_QUOTA_FILE	/app/ref/test_account_quota.json
BOOTSTRAP_REFERENCE	1
REFERENCE_DIR	/app/ref
BEAGLE_JAR	/app/ref/beagle.jar
REF_DIR	/app/ref/b37.bref3
MAP_DIR	/app/ref/maps
FASTA	/app/ref/human_g1k_v37.fasta
JOBS	1
XXM_JOB	3g
RUNTIME_RETENTION_HOURS	6
MAX_UPLOAD_MB	100
MAX_REQUEST_MB	250
MAX_BATCH_SAMPLES	5
RAILWAY_HEALTHCHECK_TIMEOUT_SEC	3600

APP_PASSWORD ani TEST_PASSWORD sa nesmú commitnúť, zapisovať do technickej správy alebo zverejniť v logu. DEMO heslo je zámerne verejné, pretože jeho rola nemôže prijímať cudzie dáta ani spustiť imputáciu. Zmena vlastníckeho alebo testovacieho hesla sa robí iba cez Railway Variables a vyvolá nové nasadenie.

11. Referenčné dáta a prvý štart

reference_manifest.tsv pripína URL, presnú veľkosť a SHA-256 každého súboru:

- Beagle JAR;
- genetické mapy GRCh37;
- 23 bref3 panelov pre chromozómy 1-22 a X z 1000 Genomes phase 3;

- komprimovanú a rozbalenú `human_g1k_v37.fasta`.

Pri prvom štarte `deploy/start.sh` overí, či je referencia kompletná. Ak nie, spustí `setup_reference.sh`. Download používa resume, každý súbor sa pred presunom z `.part` overí veľkosťou a SHA-256, mapy sa rozbalia a samtools vytvorí FASTA index `.fai`. Aplikácia sa spustí až po úspešnej kontrole.

Volume je persistentný, preto ďalší deployment iba skontroluje prítomnosť Beagle, FASTA, `.fai`, 23 `brief3` panelov a 23 máp. Kód a `/app/work` sú na ephemernom filesysteme kontajnera; referencie zostávajú na volume.

12. Bezpečnosť a životný cyklus dát

- verejný režim zlyhá pri štarte, ak chýba vlastnícke meno alebo heslo;
- HTTP Basic Auth rozlišuje roly `owner`, `test` a `demo` pomocou constant-time porovnaní;
- TEST middleware povoľuje ostrú dávkovú pipeline, ale vynucuje spoločnú perzistentnú kvótu päť prijatých genotypov denne;
- TLS končí na Railway edge;
- odpovede nastavujú `Cache-Control: no-store`, HSTS, `nosniff`, zákaz `iframe`, nulový `referrer` a zákaz kamery/mikrofónu/geolokácie;
- upload sa streamuje po 1 MB a pri prekročení limitu sa čiastočný súbor zmaže;
- názov uploadu dostane náhodný prefix a download povoľuje iba `basename` v pracovnom adresári;
- verejný režim vypína online anotáciu a BAM adresár;
- jeden procesový `JOB_LOCK` povoľuje najviac jednu imputáciu naraz;
- pracovné súbory sa mažú približne po 6 hodinách a vždy sa stratia pri redeployi; referenčný volume sa nemaže;
- aplikačné logy nie sú vo verejnom režime dostupné cez API.

HTTP Basic Auth je prevádzkové minimum, nie kompletný systém používateľských účtov. Pred spracovaním genetických údajov tretích osôb treba doplniť právny základ, informovaný súhlas, audit, incidentný proces a podľa požiadaviek aj šifrovanie uložených dát vlastným kľúčom.

13. Prevádzka a diagnostika

Základná kontrola:

```
curl https://genome-normalizer-production.up.railway.app/healthz
```

Po vlastníckom prihlásení `/api/status` musí hlásiť `java: true, beagle_jar: true, fasta: true, brief3_files: 23, default_panel: true a imputation_ready: true`.

Lokálne testy:

```
python -m unittest discover -s tests -v
bash -n targeted_impute.sh
bash -n setup_reference.sh
bash -n deploy/start.sh
```

Overenie existujúcej referencie bez siete:

```
REFERENCE_DIR=/app/ref bash setup_reference.sh --verify-only
```

Najčastejšie poruchy:

- `imputation_ready=false`: skontrolovať Java, cesty premenných a obsah volume;
- chýbajúci chromozóm: porovnať súbor s `reference_manifest.tsv` a znovu spustiť bootstrap;
- HTTP 401: nesprávne Basic Auth údaje;
- HTTP 403 na DEMO účte: požadovaná funkcia je úmyselne povolená iba vlastníkovi;
- HTTP 403 na TEST účte: účet povoľuje iba kompletnú dávkovú pipeline a jej výstupy;
- HTTP 429 na TEST účte: spoločná denná kvóta je vyčerpaná;
- HTTP 409: iná imputácia drží globálny zámok;
- HTTP 413: upload alebo celá požiadavka prekročila nastavený limit;
- nedostatočný sibling prienik: výsledok označiť ako nedostatočné dáta, nie dopĺňať 561 panelových SNP do IBD vetvy.

14. Limity

- Základná zostava je GRCh37/hg19; hg38 vyžaduje validovaný liftover.
- Produkčné WGS/WES pomocné referencie nie sú v aktuálnom Railway nasadení

kompletné; čipová normalizácia a cielená panelová imputácia sú pripravené.

- Presná uzavretá markerová šablóna platformy v5 nie je súčasťou repozitára.

Predvolený výstup preto zachováva plný meraný markerový set v otvorenej normalizovanej schéme.

- Predispozičný výstup je výskumný a informatívny, nie klinická diagnóza.

Klinicky významný nález musí potvrdiť akreditované laboratórium.